Máster en Big Data y Business Analytics

Trabajo Fin de Máster

Aplicación de técnicas de Machine Learning para la valoración económica de futbolistas profesionales y la identificación de activos potencialmente infravalorados

Autor: Álvaro Rodríguez Parro

Madrid, septiembre de 2026

Índice

1 Introducción 1
1.1 Contexto y motivación 1
1.2 Problema de negocio y objetivos del trabajo 1
2 Marco teórico y Estado del Arte 2
2.1 Valoración económica de jugadores profesionales 2
2.2 Técnicas de Machine Learning aplicadas al fútbol 2
2.3 Estudios previos y factores determinantes del valor 3
3 Datos y metodología 4
3.1 Fuentes de información y descripción de los datos 4
3.2 Construcción del dataset 4
3.3 Ingeniería de características 5
3.4 Análisis exploratorio 5
3.5 Preparación del dataset para la modelización 7
4 Desarrollo de modelos predictivos 8
4.1 Técnicas de modelización 8
4.2 Evaluación y comparación de resultados 9
4.3 Selección del modelo final 10
4.4 Interpretación de resultados 10
5 Aplicación al negocio 12
5.1 Identificación de posibles activos infravalorados 12
5.2 Utilidad para procesos de scouting y fichajes 13
5.3 Limitaciones de la propuesta 15
6 Conclusiones y líneas futuras 16
6.1 Conclusiones 16
6.2 Mejoras y líneas futuras 17
6.3 Aplicaciones empresariales 18

Bibliografía 19

Anexos 19

1 Introducción

1.1 Contexto y motivación

El mercado de fichajes del fútbol profesional constituye un entorno en el que se toman decisiones económicas de elevada relevancia, y en el que la valoración de los jugadores está condicionada por numerosos factores deportivos y contextuales.

La disponibilidad creciente de datos deportivos ofrece la posibilidad de complementar los procesos tradicionales de evaluación de futbolistas mediante técnicas de análisis de datos y *Machine Learning*. Estas técnicas permiten identificar relaciones complejas entre diferentes características de los jugadores, y obtener estimaciones de su valor de mercado a partir de información histórica.

La motivación principal de este trabajo surge, por tanto, de la posibilidad de aplicar estas técnicas a un problema con una clara dimensión empresarial: proporcionar una herramienta que pueda complementar el trabajo de los departamentos de *scouting*, y apoyar la identificación de jugadores cuyo valor de mercado observado difiera significativamente del valor estimado por un modelo predictivo**.**

Esta aproximación no pretende sustituir el conocimiento de los profesionales encargados de analizar el mercado de fichajes, sino proporcionar una fuente adicional de información que facilite la detección de oportunidades y contribuya a una toma de decisiones basada en datos.

1.2 Problema de negocio y objetivos del trabajo

Desde una perspectiva de negocio, uno de los principales problemas de los clubes de fútbol consiste en disponer de una estimación objetiva y reproducible que permita contrastar el valor de mercado observado de un jugador con el valor que podría esperarse, a partir de sus características y rendimiento.

En este contexto, el presente trabajo plantea el desarrollo de un modelo de *Machine Learning*, capaz de estimar ese valor de mercado. A partir de las predicciones obtenidas, se analizarán posteriormente las diferencias entre el valor observado y el valor estimado, con el objetivo de identificar jugadores que puedan constituir potenciales oportunidades de inversión.

El objetivo principal del estudio es, por tanto, desarrollar el modelo para la estimación del valor de mercado de futbolistas profesionales, basado principalmente en el análisis de características personales y de rendimiento puramente deportivo; evaluar ese modelo, para saber hasta dónde esas características más directas y menos contextuales o extradeportivas pueden

explicar cómo se mueve este mercado, y utilizar sus predicciones como herramienta de apoyo a la identificación de posibles activos infravalorados.

2 Marco teórico y Estado del Arte

2.1 Valoración económica de jugadores profesionales

La valoración económica de los futbolistas profesionales constituye un problema complejo en el que intervienen múltiples factores, relacionados tanto con el rendimiento deportivo como con las características individuales del jugador, y el contexto en el que desarrolla su actividad.

Entre las variables que aparecen de forma recurrente en la literatura se encuentran la edad, el número de minutos disputados, las apariciones, los goles y las asistencias. La revisión sistemática realizada por *Franceschi et al.* (2024), que analiza diferentes estudios sobre los determinantes de la valoración de futbolistas, identifica precisamente estas variables entre los factores utilizados con mayor frecuencia en los modelos de valoración. El estudio también señala la existencia de relaciones no lineales entre determinadas características de los jugadores y su valor de mercado, especialmente en el caso de la edad.

Otro aspecto importante a tener en cuenta es que el valor de mercado no depende exclusivamente de las estadísticas individuales del jugador. Variables relacionadas con su posición, el club al que pertenece, la competición en la que participa o su trayectoria profesional también pueden contribuir a explicar las diferencias observadas entre jugadores.

Una fuente de información ampliamente utilizada en este ámbito es *Transfermarkt*, plataforma especializada en información sobre fútbol profesional que publica estimaciones de valor de mercado de los jugadores. Estas valoraciones han sido utilizadas en diferentes investigaciones como variable objetivo para analizar los factores asociados al valor económico de los futbolistas. *Herm, Callsen-Bracker y Kreis (2014*), por ejemplo, estudiaron la precisión y los factores relacionados con las valoraciones de jugadores realizadas por la comunidad de usuarios de *Transfermarkt*.

2.2 Técnicas de Machine Learning aplicadas al fútbol

El *Machine Learning* permite desarrollar modelos capaces de identificar relaciones entre diferentes variables y una variable objetivo a partir de datos históricos. En

problemas relacionados con el deporte, estas técnicas pueden utilizarse para abordar tareas como la predicción del rendimiento, la estimación de valores económicos, o incluso la predicción de ganadores tanto a nivel individual como de equipo.

En el contexto de la valoración económica de futbolistas, una de las principales dificultades consiste en que la relación entre las características de un jugador y su valor de mercado no tiene por qué ser lineal. Por ello, además de los modelos estadísticos tradicionales, resulta de interés utilizar algoritmos capaces de representar relaciones no lineales.

En este trabajo se comparan tres enfoques basados en árboles —Random Forest, Gradient Boosting y XGBoost— con un modelo de Regresión Lineal, utilizado como referencia. Esta comparación permite analizar si los modelos capaces de representar relaciones no lineales ofrecen una mejora respecto a una aproximación lineal más sencilla.

2.3 Estudios previos y factores determinantes del valor

La literatura existente muestra que el valor de mercado de un futbolista está determinado por la combinación de diferentes características deportivas, personales y contextuales.

El estudio *Money Talks* (*2020*), realizado sobre jugadores de las principales ligas europeas, analiza un conjunto amplio de variables individuales y deportivas y muestra que los factores asociados al valor de mercado pueden variar en función de las características del jugador y de su posición.

Serna Rodríguez, Ramírez Hassan y Coad (2019) analizaron los factores asociados al valor de jugadores de alto rendimiento mediante un modelo de *Bayesian Model Averaging*, considerando, entre otros elementos, la edad, el rendimiento y la participación con las selecciones nacionales.

Más recientemente, el uso de técnicas de *Machine Learning* ha permitido abordar esta problemática mediante modelos capaces de representar relaciones más complejas entre las variables. *McHale y Holmes (2023*) aplicaron diferentes técnicas de *Machine Learning* a la estimación de las tarifas de transferencia de futbolistas profesionales, incluyendo XGBoost.

A partir de esta literatura, el presente trabajo parte de un conjunto de variables relacionadas con las características del jugador y su rendimiento durante la temporada. Se utilizan diferentes algoritmos de predicción y se incorpora una evaluación temporal para comprobar el comportamiento del modelo sobre una temporada posterior a las utilizadas durante el entrenamiento. Además, el análisis de la importancia de las variables permite estudiar qué factores tienen mayor relevancia en las predicciones obtenidas.

Este planteamiento permite conectar el análisis académico con una aplicación práctica orientada a la identificación de posibles oportunidades en el mercado de fichajes.

3 Datos y metodología

3.1 Fuentes de información y descripción de los datos

Para el desarrollo del trabajo se utiliza un conjunto de datos público sobre fútbol profesional procedente de *Transfermarkt*, distribuido a través del repositorio público *Transfermarkt Dataset* y disponible en *Kaggle*.

El dataset presenta una estructura relacional compuesta por diferentes tablas, entre las que se encuentran información sobre jugadores, apariciones, valoraciones de mercado, partidos y clubes. Esta estructura permite combinar información de diferentes dimensiones del fútbol profesional para construir las variables utilizadas posteriormente en el modelo.

Como primer paso, se revisaron las diferentes tablas disponibles, analizando su estructura, variables, tipos de datos y volumen de información, con el objetivo de determinar qué elementos podían resultar relevantes para el objetivo del estudio.

3.2 Construcción del dataset

A partir de la revisión inicial de las tablas disponibles, se seleccionaron las variables consideradas más relevantes para analizar la relación entre las características y el rendimiento de los futbolistas y su valor de mercado, centrándonos principalmente en aspecto deportivos y dejando un poco aparcados aspectos más contextuales como la información sobre los clubs o sobre transferencias pasadas.

Mediante la combinación y transformación de la información procedente de las distintas tablas se construyó un dataset específico para este trabajo, denominado dataset_final. Este conjunto constituye la base sobre la que posteriormente se realizó el proceso de ingeniería de características y el análisis exploratorio.

El conjunto cuenta con 74.669 observaciones o filas. Cada una de ellas representa una única combinación jugador - temporada. El periodo temporal abarca de la temporada 2012 a la temporada 2023.

dataset_final integra información relativa a las características de los jugadores, su posición, rendimiento deportivo, participación en partidos y valor de mercado, permitiendo disponer en un único conjunto de la información necesaria para el análisis posterior.

3.3 Ingeniería de características

Una vez construido el dataset_final, se llevó a cabo un proceso de ingeniería de características, enriqueciendo así el conjunto de datos. Estas nuevas variables fueron añadidas a nuestro dataset final.

Entre las principales variables derivadas se incluyeron la edad, el número de victorias, el porcentaje de victorias, los minutos medios por aparición y diferentes métricas normalizadas por 90 minutos, como los goles, asistencias, tarjetas y contribución ofensiva.

Estas transformaciones permitieron complementar las variables originales con indicadores que aportan información adicional sobre el rendimiento y el contexto competitivo de cada jugador. El resultado de este proceso constituyó el conjunto de datos final utilizado para el análisis exploratorio.

3.4 Análisis exploratorio

Sobre el dataset resultante se realizó un análisis exploratorio de los datos (EDA), con el objetivo de comprender la distribución de las variables, detectar posibles valores anómalos o ausentes e identificar relaciones relevantes con el valor de mercado de los jugadores.

En primer lugar, se analizó la distribución de la variable objetivo, el valor de mercado, observándose una elevada concentración de jugadores en valores de mercado relativamente bajos y una distribución claramente asimétrica hacia valores elevados.

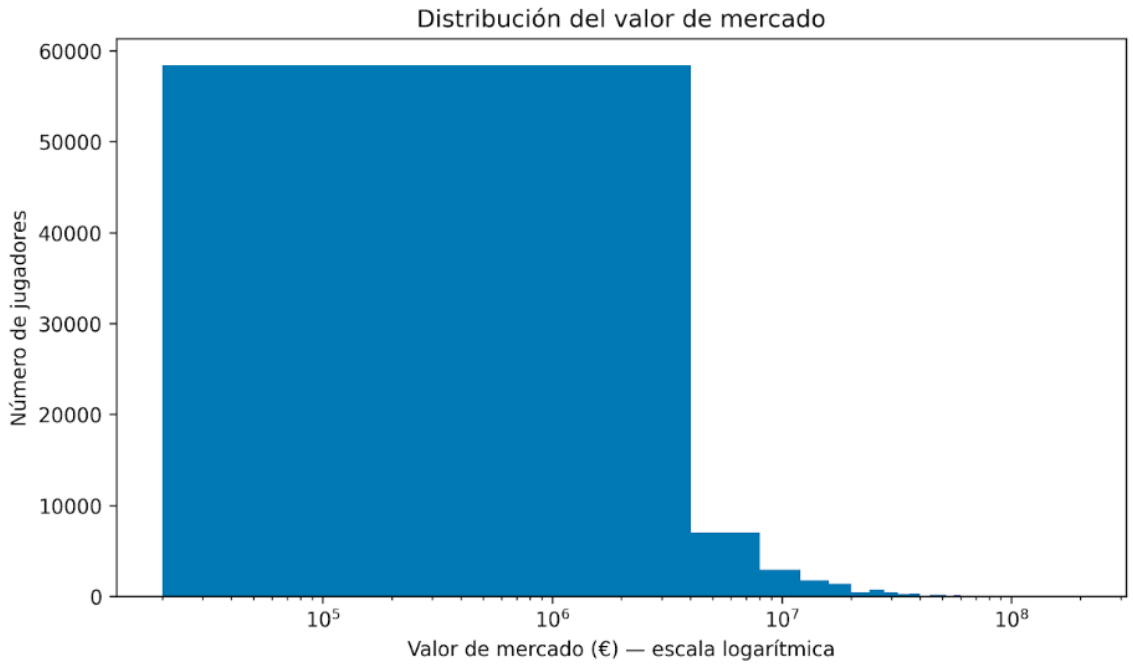


Figura 1. Distribución logarítmica de la variable objetivo valor de mercado

También se estudió la relación entre el valor de mercado y variables como la edad, la posición, el pie dominante y los principales indicadores de rendimiento. El análisis de correlaciones permitió identificar relaciones relevantes entre las variables numéricas y detectar determinados casos de elevada correlación entre predictores.

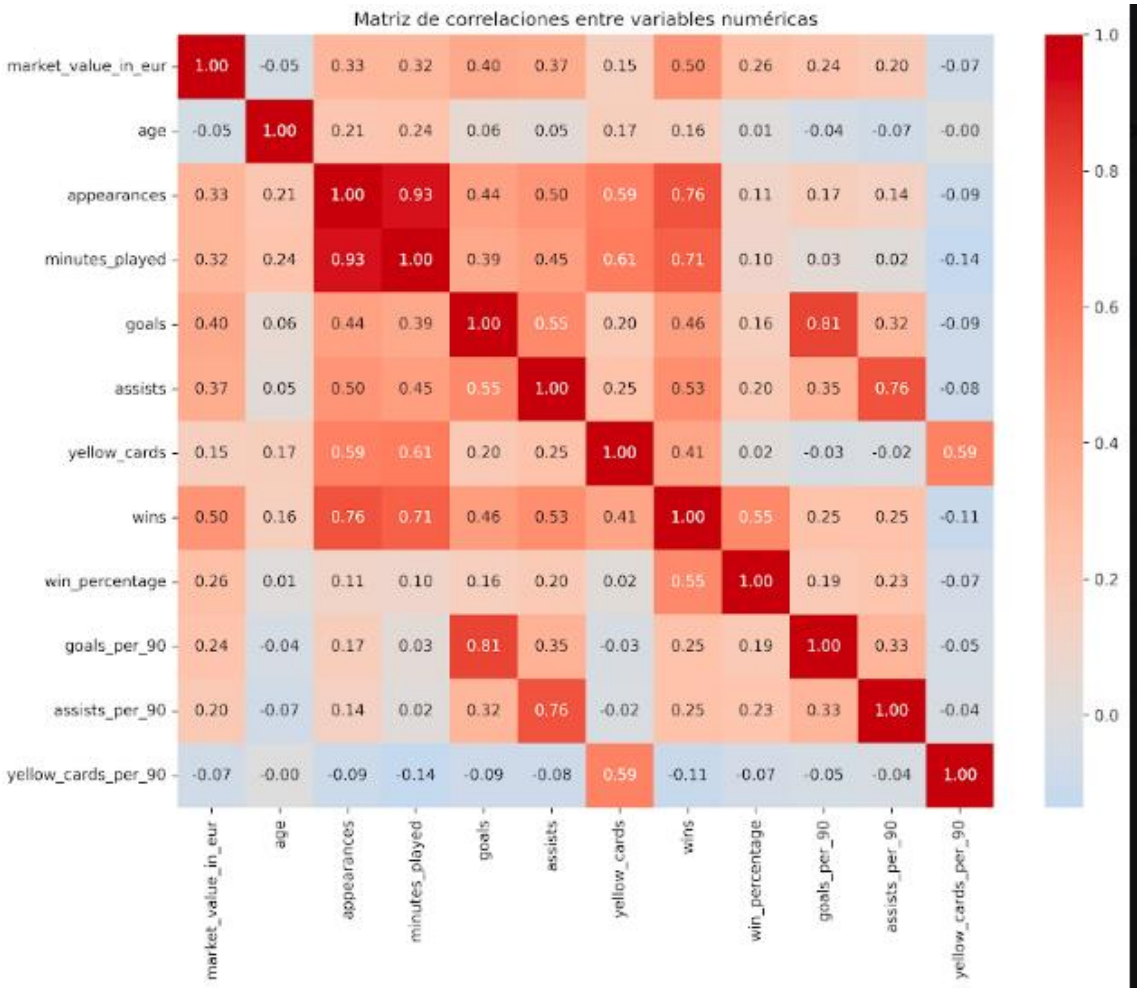


Figura 2. Matriz de correlaciones entre variables numéricas

Asimismo, se analizaron las variables expresadas por 90 minutos, observándose valores extremos asociados a jugadores con un número reducido de minutos disputados. Este análisis fue especialmente relevante para establecer posteriormente los criterios de preparación del dataset destinado a la modelización.

Los resultados del análisis exploratorio permitieron determinar qué variables podían resultar útiles para los modelos y qué transformaciones o exclusiones debían realizarse antes de la fase de entrenamiento.

3.5 Preparación del dataset para la modelización

A partir de las conclusiones obtenidas durante el análisis exploratorio se construyó el dataset definitivo destinado a la modelización, denominado dataset_modeling.

En esta fase se revisaron las variables disponibles y se eliminaron aquellas que presentaban redundancia, escasa utilidad predictiva o problemas derivados de su construcción. En particular, se descartaron determinadas variables derivadas y las relacionadas con las expulsiones, así como otras variables que no se consideraron adecuadas como predictores.

Para las métricas expresadas por 90 minutos se estableció un umbral mínimo de 180 minutos disputados. Los valores correspondientes a jugadores que no alcanzaban este umbral se trataron como valores ausentes, evitando así que participaciones muy reducidas generasen ratios extremos. Estos valores fueron posteriormente tratados durante el proceso de preprocesamiento mediante imputación.

Finalmente, la variable objetivo, *market_value_in_eur*, se transformó mediante *log1p* para reducir el efecto de su fuerte asimetría. Para evaluar el comportamiento del modelo ante datos temporales posteriores a los utilizados para su entrenamiento, se realizó una división temporal, utilizando las temporadas 2012–2022 para entrenamiento y 2023 para evaluación.

$$y = log(1 + market_value_in_eur)$$

La transformación permite trabajar con una variable objetivo más equilibrada y facilita el aprendizaje de los modelos ante la elevada dispersión existente en los valores de mercado. Una vez realizadas las predicciones, estas se transformaron nuevamente a euros mediante la operación inversa:

$$\hat{market_value} = e^{\hat{y}} - 1$$

De este modo, el proceso seguido puede resumirse como:

tablas originales → dataset_final → ingeniería de características → EDA → dataset_modeling → modelos predictivos

4 Desarrollo de modelos predictivos

4.1 Técnicas de modelización

Con el conjunto de datos preparado, se procedió al entrenamiento y comparación de diferentes modelos de regresión con el objetivo de estimar el valor de mercado de los futbolistas.

Como modelo de referencia se utilizó una Regresión Lineal, que permite establecer una aproximación sencilla de la relación entre las variables predictoras y el valor de mercado. Su principal ventaja es su facilidad de interpretación, aunque presenta limitaciones cuando las relaciones entre las variables no son lineales.

A continuación, se utilizaron tres modelos basados en árboles de decisión: Random Forest, Gradient Boosting y XGBoost.

Random Forest construye un conjunto de árboles de decisión independientes y combina sus predicciones para obtener el resultado final. Esta metodología permite representar relaciones no lineales y reducir la dependencia respecto a un único árbol de decisión. Es robusto frente a valores extremos, aunque puede generar modelos menos interpretables .

Gradient Boosting construye los árboles de manera secuencial, incorporando nuevos modelos que buscan corregir progresivamente los errores cometidos por los anteriores. Esta estrategia permite obtener modelos con una elevada capacidad predictiva, manteniendo un control sobre la complejidad mediante parámetros como la profundidad de los árboles y la tasa de aprendizaje, aunque su entrenamiento secuencial puede incrementar el coste computacional y hacerlo más sensible a determinados parámetros.

Por último, se utilizó XGBoost, un algoritmo de *gradient boosting* optimizado para problemas de aprendizaje supervisado. Se seleccionó debido a su capacidad para representar relaciones no lineales y sus interacciones, así como por su utilización en trabajos previos relacionados con la estimación de valores económicos de futbolistas. Este modelo incorpora mejoras de eficiencia y regularización respecto a los métodos tradicionales de *gradient boosting.*

Los modelos se entrenaron inicialmente utilizando una configuración de parámetros razonable, sin realizar una búsqueda exhaustiva de hiperparámetros. Esta decisión permitió centrar el trabajo en la comparación metodológica y en la aplicación e interpretación del modelo.

Todos los modelos utilizan la misma variable objetivo y el mismo conjunto de predictores, de forma que la comparación de sus resultados sea homogénea. La evaluación definitiva se realiza sobre la temporada 2023, reservada previamente como conjunto de prueba temporal.

4.2 Evaluación y comparación de resultados

Para evaluar el comportamiento de los modelos se utilizaron diferentes métricas de regresión. Se consideraron el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el coeficiente de determinación R^2.

El MAE representa el error absoluto medio cometido por el modelo en sus predicciones, mientras que el RMSE penaliza en mayor medida los errores de gran magnitud. Por su parte, el coeficiente R^2 indica la proporción de variabilidad de la variable objetivo que es explicada por el modelo. En el caso de las métricas calculadas sobre la escala logarítmica, valores inferiores de MAE y RMSE representan un menor error, mientras que valores superiores de R^2 indican un mejor ajuste.

La comparación definitiva se realizó utilizando la separación temporal descrita anteriormente: los datos correspondientes a las temporadas 2012–2022 se utilizaron para el entrenamiento y los correspondientes a la temporada 2023 se reservaron para la evaluación.

Los resultados obtenidos fueron los siguientes:

Modelo	MAE (log)	RMSE (log)	R²	MAE (€)	RMSE (€)
Regresión Lineal	0,9725	1,1924	0,4562	4.220.569 €	10.670.283 €
Random Forest	0,9305	1,1481	0,4959	3.966.855 €	9.970.177 €
Gradient Boosting	0,9163	1,1269	0,5144	3.960.585 €	10.034.612 €
XGBoost	**0,8996**	**1,1114**	**0,5276**	**3.840.865 €**	**9.697.993 €**

Tabla 1. Comparación del rendimiento de los modelos sobre el conjunto de prueba temporal

Los resultados muestran una mejora progresiva del rendimiento al pasar de la regresión lineal a los modelos basados en árboles. XGBoost obtuvo los mejores resultados en las cinco métricas consideradas, alcanzando un R² de 0,5276 y un MAE de 3,84 millones de euros sobre el conjunto de prueba temporal.

Estos resultados sugieren que la capacidad de los modelos basados en árboles para representar relaciones no lineales resulta útil para este problema. La diferencia respecto a la Regresión Lineal es especialmente relevante teniendo en cuenta el comportamiento no lineal observado previamente entre determinadas variables, como la edad y el valor de mercado.

Cabe destacar que se realizó una evaluación inicial mediante una división aleatoria de los datos. En este escenario XGBoost también obtuvo el mejor resultado, con un R^2de 0,5285. Un R^2 prácticamente idéntico indica que nuestro resultado no parece depender de una ventaja artificial del split aleatorio.

No obstante, para la selección definitiva del modelo se priorizaron los resultados obtenidos mediante la división temporal, al proporcionar una evaluación más exigente sobre una temporada posterior no utilizada durante el entrenamiento.

4.3 Selección del modelo final

A partir de los resultados obtenidos en la evaluación temporal, se seleccionó XGBoost como modelo final para la estimación del valor de mercado de los futbolistas.

La selección se realizó atendiendo conjuntamente a las métricas calculadas en la escala logarítmica y en la escala original de euros. XGBoost obtuvo el menor MAE y RMSE en ambas escalas y, al mismo tiempo, el mayor coeficiente de determinación entre los cuatro modelos evaluados.

El modelo alcanzó un $R^2 = 0{,}5276$ sobre la temporada 2023. Esto indica que aproximadamente el 52,8 % de la variabilidad observada en el logaritmo del valor de mercado es recogida por el modelo en este conjunto de prueba. El resultado debe interpretarse teniendo en cuenta la naturaleza del problema, ya que el valor económico de un futbolista depende de factores que no están necesariamente disponibles en el conjunto de datos, como las condiciones contractuales, la situación económica de los clubes, la duración restante del contrato o determinados factores de mercado. Precisamente uno de los objetivos de este estudio era comprobar cuánto peso pueden tener variables puramente deportivas en la determinación de este valor económico.

4.4 Interpretación de resultados

Una vez seleccionado XGBoost como modelo final, se analizó su comportamiento para comprender qué variables presentan una mayor relevancia en las predicciones.

Para ello se utilizaron dos enfoques complementarios: la importancia de variables propia del modelo XGBoost y la importancia mediante permutación sobre el conjunto de prueba correspondiente a la temporada 2023.

La importancia proporcionada internamente por XGBoost muestra que *wins* es la variable con mayor peso relativo dentro del modelo, con mucha diferencia sobre las demás. Le seguiría *age* y, a mayor distancia, diferentes variables relacionadas con el rendimiento, la participación y las características del jugador. Esta medida representa la contribución relativa de las variables a las decisiones de los árboles del modelo. La importancia de una variable dentro de un modelo de este tipo no debe interpretarse de forma aislada, especialmente cuando existen variables predictoras correlacionadas.

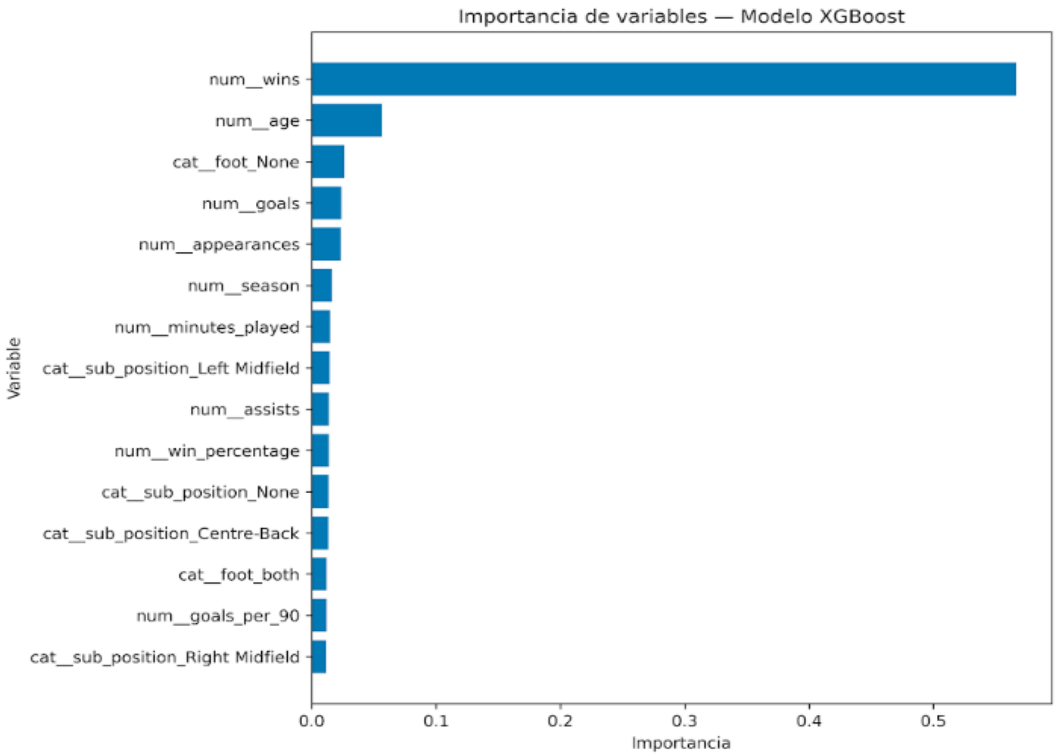


Figura 3. Análisis de importancia de las variables en XGBoost

Para complementar este resultado se calculó la importancia mediante permutación. Este procedimiento consiste en modificar aleatoriamente los valores de una variable del conjunto de prueba y observar cuánto empeora el rendimiento del modelo. Una mayor reducción del R^2 indica una mayor dependencia del modelo respecto a dicha variable.

Los resultados de este segundo análisis sitúan nuevamente a *wins* como la variable con mayor importancia, seguida de *age, minutes_played* y *appearances*. El resto de variables presenta reducciones considerablemente menores del rendimiento.

Aunque la importancia interna de XGBoost sitúa a *wins* como la variable más relevante, un análisis de sensibilidad mostró que eliminar *wins* y reentrenar el modelo apenas modifica el rendimiento predictivo (R^2 = 0,5281 frente a 0,5276). Esto sugiere que parte de la información contenida en *wins* está compartida con variables relacionadas, especialmente *appearances* y *win_percentage*.

Eso es bastante tranquilizador: el resultado no depende de una única variable de manera artificial.

A pesar de esta redundancia, se decidió mantener *wins* en el modelo final debido a su interpretación directa como indicador del volumen de victorias obtenido durante la temporada. El análisis de sensibilidad permite, además, comprobar que su inclusión no condiciona de forma relevante el rendimiento global del modelo.

5 Aplicación al negocio

5.1 Identificación de posibles activos infravalorados

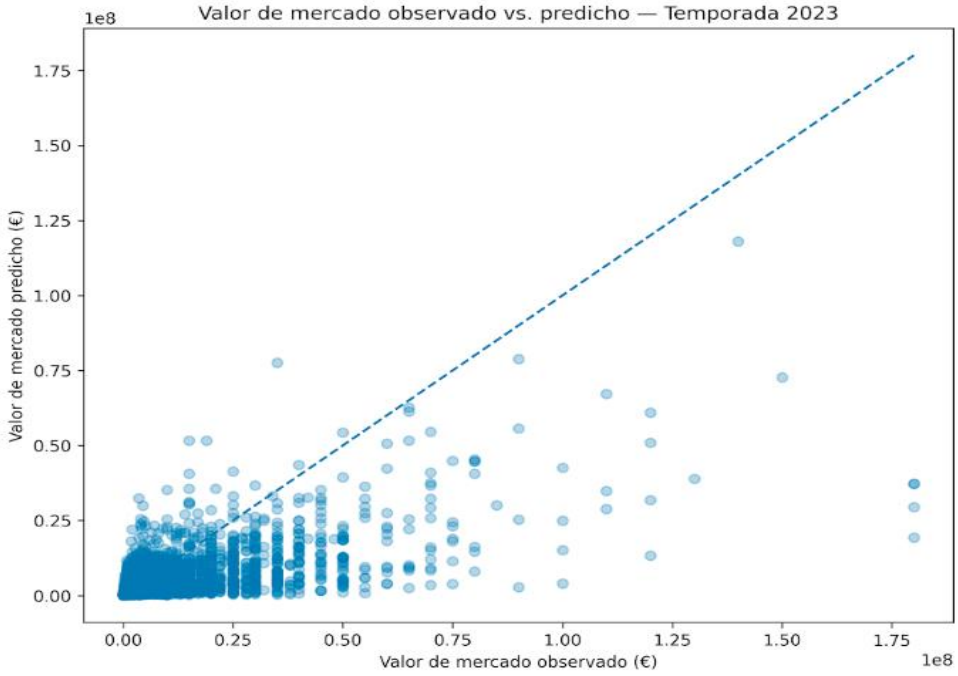


Figura 4. Valor de mercado observado vs predicho temporada 2023

Una vez seleccionado y entrenado el modelo XGBoost, se utilizó su capacidad predictiva para realizar una aplicación práctica orientada a la identificación de posibles oportunidades de mercado.

Para cada jugador de la temporada 2023 se obtuvo una estimación de su valor de mercado y se comparó con el valor observado en el conjunto de datos.

El modelo presenta un comportamiento razonable para una gran parte de la distribución, pero tiene mayores dificultades para estimar los valores extremos, especialmente en jugadores con valores de mercado muy elevados.

A partir de esta comparación se calculó la diferencia absoluta entre ambos valores y, adicionalmente, la diferencia relativa y la diferencia en la escala logarítmica.

Con el objetivo de evitar que las diferencias producidas en jugadores con valores de mercado muy reducidos dominaran el análisis, se establecieron dos condiciones para la selección inicial de candidatos:

- Valor de mercado observado igual o superior a 1 millón de euros.
- Valor estimado por el modelo dos veces superior al valor observado.

La aplicación de estos criterios produjo un total de 237 candidatos.

Estos jugadores se consideran potenciales activos infravalorados desde la perspectiva del modelo, pero esta clasificación no implica que su valor de mercado real esté necesariamente infravalorado. Una diferencia elevada entre la predicción y el valor observado puede deberse tanto a una oportunidad real como a un error de predicción o a factores relevantes que no están presentes en los datos utilizados.

Para comprobar hasta qué punto estas diferencias podían estar asociadas a una evolución posterior del valor de mercado, se realizó además una validación retrospectiva sobre una muestra de candidatos, ya que contamos con las valoraciones de años posteriores a 2023 en la mayoría de los casos.

Para esta validación se seleccionaron, de entre ese grupo de 237 candidatos , los 10 primeros de la lista (con mayor diferencia entre valor predicho y observado), los diez últimos, y 10 de posiciones intermedias de la tabla. Consideramos que esa validación es exitosa cuando el valor observado en el futuro se ha multiplicado al menos por 1,5 respecto al valor observado en 2023. Es decir, éxito significaría que el modelo predijo un valor mucho más alto que el observado para ese 2023, y en el futuro se cumplió esa revalorización al menos en x1,5.

	grupo	casos	con_datos_posteriores	revalorizacion_50	porcentaje_revalorizacion_50
0	Intermedios	10	9	1	11.111111
1	Menor gap	10	9	2	22.222222
2	Top 10	10	8	4	50.000000

Tabla 2. Resultados validación retrospectiva potenciales activos infravalorados

No obstante, los resultados de esta comprobación deben interpretarse de forma exploratoria, dado que la muestra fue seleccionada a partir de las propias predicciones del modelo.

5.2 Utilidad para procesos de scouting y fichajes

En un contexto de búsqueda de nuevos jugadores, el modelo permitiría procesar información de diferentes futbolistas y obtener una estimación homogénea de su valor. La comparación entre esta estimación y el valor de mercado disponible permitiría establecer un filtro inicial de candidatos que posteriormente podrían ser analizados por los responsables de *scouting*. Esta aproximación puede resultar especialmente útil cuando el número de jugadores potencialmente analizables es elevado.

No obstante, la predicción obtenida no debe interpretarse como una valoración definitiva del jugador ni como una recomendación automática de fichaje. La decisión final requeriría incorporar información adicional que no forma parte del modelo, como las condiciones contractuales, el coste de una posible transferencia, la disponibilidad del jugador o las necesidades del equipo.

Desde el punto de vista de la aplicación práctica, el modelo también puede integrarse en un flujo de trabajo sencillo: entrada de las características de un jugador → predicción de su valor de mercado → comparación con el valor observado → identificación de posibles candidatos para un análisis posterior.

De esta forma, la propuesta desarrollada no pretende sustituir el trabajo de los profesionales encargados del *scouting*, sino proporcionar una herramienta cuantitativa que facilite una primera fase de cribado y ayude a orientar el análisis hacia determinados perfiles.

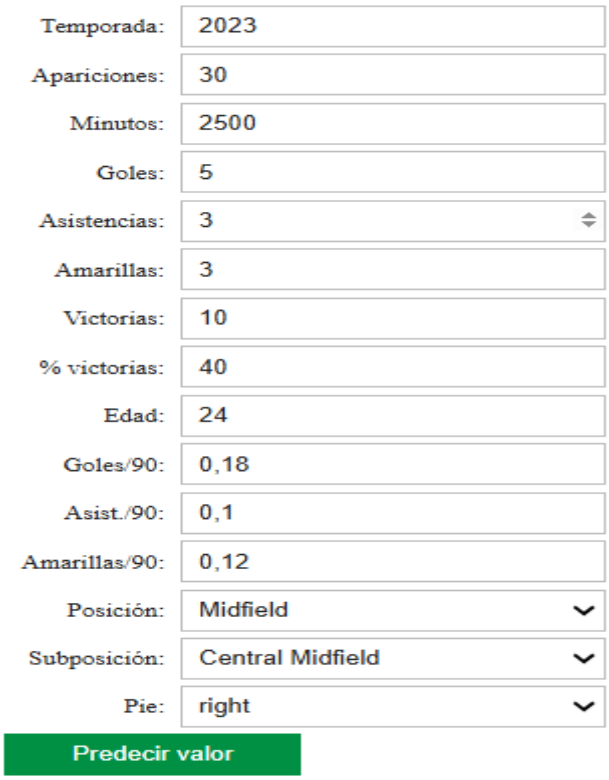


Figura 5. Aplicación para la estimación del valor de mercado de un jugador

Como demostración de esta posibilidad de productivización, se desarrolló una aplicación sencilla en Python mediante *ipywidgets*, que permite introducir las características de un jugador y obtener automáticamente su valor de mercado estimado.

5.3 Limitaciones de la propuesta

La propuesta desarrollada presenta varias limitaciones que deben tenerse en cuenta a la hora de interpretar sus resultados y trasladarlos a un contexto real de toma de decisiones.

En primer lugar, el modelo utiliza únicamente las variables disponibles en el conjunto de datos. Aunque estas permiten recoger información sobre las características y el rendimiento deportivo de los jugadores, existen otros factores que pueden influir en su valor de mercado y que no han sido considerados. Entre ellos se encuentran las condiciones contractuales, las características económicas de una posible transferencia, el tipo de club en el que se encuentre jugando ese jugador, factores de marketing o publicitarios, etc.

Otra limitación está relacionada con el rendimiento del modelo. El XGBoost seleccionado alcanza un R^2de 0,5276 en la evaluación temporal, por lo que existe una parte relevante de la variabilidad del valor de mercado que no es explicada por las variables utilizadas. Además, el modelo presenta una tendencia a subestimar los valores de los jugadores con valoraciones especialmente elevadas, aspecto que resulta coherente con la elevada dispersión existente en la variable objetivo.

También debe tenerse en cuenta que la identificación de posibles activos infravalorados depende de los criterios establecidos. En este trabajo se seleccionaron jugadores con un valor observado de al menos 1 millón de euros y una predicción igual o superior al doble de dicho valor. Estos umbrales permiten definir un procedimiento operativo, pero no implican que los jugadores seleccionados estén realmente infravalorados.

Por último, la validación retrospectiva realizada sobre una muestra de candidatos debe interpretarse como una comprobación exploratoria y no como una validación independiente del modelo. Los jugadores incluidos en esta comprobación fueron previamente seleccionados precisamente por presentar una diferencia elevada entre su valor observado y el valor estimado. Por tanto, los resultados posteriores permiten aportar información adicional sobre la evolución de estos jugadores, pero no permiten establecer por sí solos una relación causal entre la predicción del modelo y su posterior revalorización.

En consecuencia, la propuesta debe entenderse como una herramienta de apoyo al análisis y al proceso de selección inicial de jugadores, que podría complementarse con información deportiva, económica y contractual adicional antes de adoptar cualquier decisión de fichaje.

6 Conclusiones y líneas futuras

6.1 Conclusiones

El presente trabajo ha abordado el problema de la estimación del valor de mercado de futbolistas profesionales mediante técnicas de Machine Learning, utilizando información histórica sobre sus características y rendimiento deportivo. El objetivo principal era desarrollar un modelo y ver hasta dónde es capaz de estimar dicho valor de mercado con las variables disponibles.

La conclusión principal es que estamos antes un mercado complejo, en el que la variable objetivo estudiada, valor de mercado, necesita de muchos parámetros y muchas variables, algunas difíciles de medir o cuantificar, para ser estimada de manera precisa. Las características puramente individuales y deportivas, sin el contexto del club, de la competición o de relaciones contractuales, se quedan muy cortas si el objetivo es elaborar un modelo relativamente fiable para predecir los valores del mercado de fichajes.

El análisis exploratorio permitió comprobar que el valor de mercado presenta una distribución fuertemente asimétrica y que determinadas variables muestran una relación relevante con la variable objetivo. Entre ellas destacan las victorias, los goles o los minutos disputados. También se observaron relaciones no lineales, especialmente en el caso de la edad, lo que justificó la utilización de modelos capaces de representar este tipo de relaciones.

La comparación de los cuatro modelos desarrollados mostró diferencias en su capacidad predictiva. La Regresión Lineal obtuvo el menor rendimiento de los modelos evaluados, mientras que los métodos basados en árboles presentaron mejores resultados. Entre estos, destacamos a XGBoost.

La evaluación temporal resulta especialmente relevante, ya que permite comprobar el comportamiento del modelo sobre una temporada posterior a las utilizadas durante el entrenamiento. Los resultados muestran que el modelo mantiene capacidad predictiva sobre datos temporales no utilizados durante su aprendizaje, aunque existe todavía una parte considerable de la variabilidad del valor de mercado que no queda explicada por las variables disponibles.

El modelo consigue representar razonablemente bien la masa central, pero tiene más dificultades con los valores extremos.

Es cierto que un R^2 de ~0,53 puede parecer un tanto pobre. Cabe preguntarnos si podríamos haber conseguido un índice mayor de alguna manera, por ejemplo, filtrando más (seleccionando solo grandes Ligas) o eliminando valores extremos. Y

la respuesta puede ser afirmativa, pero entonces probablemente conseguiríamos un modelo menos representativo del mercado real. Porque esos jugadores con valores extremos, por ejemplo, valorados en 150 M€, son pieza fundamental del mercado que queremos estudiar.

El análisis de interpretabilidad mostró que la variable *wins* presenta una importancia destacada en las predicciones. El análisis de sensibilidad realizado eliminando esta variable produjo resultados prácticamente idénticos, lo que indica que existe información compartida entre esta variable y otras medidas de participación y rendimiento. En cualquier, tiene bastante sentido pensar que un jugador con un gran número de victorias y de minutos o apariciones, juegue en un equipo ganador y sea importante dentro de ese equipo. Si echamos un vistazo al mercado actual, podemos comprobar que jugadores que forman parte de equipos top tiene un valor realmente alto, aunque de manera objetiva o subjetiva tengan menos calidad futbolística que jugadores que lo hacen en equipos menores.

6.2 Mejoras y líneas futuras

El trabajo desarrollado puede ampliarse mediante la incorporación de información adicional y mediante diferentes mejoras metodológicas.

El techo natural del modelo pasa por la falta de variables fundamentales que ayudan a determinar el valor de un futbolista.

Entre las variables puramente ligadas al rendimiento individual, echamos en falta algunas que influyen más directamente a defensas y porteros. La incorporación de métricas como recuperaciones, duelos, intervenciones defensivas o paradas podría permitir una representación más completa del rendimiento de estos perfiles, añadiéndose a las que ya tenemos, como goles o asistencias. No obstante, cabe destacar que se realizó un análisis del modelo de manera individualizada por posición, y no se apreciaron diferencias notables.

También sería clave incorporar variables relacionadas con el contexto económico y contractual del jugador y del club al que pertenece. Dos jugadores de 24 años, centrocampistas, con números estadísticos relativamente similares pueden tener valores completamente diferentes. Por ejemplo, uno puede estar jugando en un club de Champions y otro en una liga menor. El modelo puede observar valores en cuanto a minutos, goles, porcentaje de victorias en su liga doméstica o asistencias similares; y sin embargo, la falta de información sobre la magnitud del club hace que falle en su predicción.

Por eso un R^2 de 0,53 puede ser perfectamente razonable en nuestro caso.

Otras variables importantes que ayudarían a mejorar la precisión y fiabilidad de nuestro modelo podrían ser la reputación, las internacionalidades, o el historial de lesiones del jugador.

Otra mejora aplicable podría ser la de acotar el análisis a un grupo de equipos o ligas que sean de niveles similares. Estudios pasados obtuvieron mejores resultados debido, entre otras cosas, a que redujeron sus datos a un puñado de ligas.

Desde el punto de vista metodológico, una posible ampliación consistiría en realizar una optimización más exhaustiva de los hiperparámetros de los modelos, aunque sin llegar a forzarlos de manera artificial, y estudiar técnicas adicionales de Machine Learning.

6.3 Aplicaciones empresariales

Desde el punto de vista empresarial, el modelo permitió establecer un procedimiento de *screening* para identificar jugadores cuyo valor estimado era significativamente superior a su valor observado. La aplicación de los criterios definidos permitió obtener 237 candidatos, que pueden considerarse potenciales oportunidades para un análisis posterior.

En conjunto, los resultados muestran que las técnicas de *Machine Learning* pueden constituir una herramienta útil para complementar los métodos tradicionales de análisis del mercado futbolístico. La propuesta desarrollada permite transformar información histórica de jugadores en estimaciones cuantitativas y utilizar dichas estimaciones como mecanismo de apoyo para una primera fase de identificación de posibles oportunidades de mercado.

La propuesta desarrollada presenta diferentes posibilidades de aplicación en un entorno profesional relacionado con la gestión deportiva.

Una primera aplicación sería la creación de un sistema de apoyo al scouting, capaz de procesar grandes cantidades de jugadores y generar una primera selección de perfiles que presenten diferencias relevantes entre su valor observado y el estimado por el modelo.

El modelo también podría utilizarse como herramienta de seguimiento de jugadores, permitiendo actualizar periódicamente las estimaciones a medida que se incorporan nuevas temporadas y nuevos datos de rendimiento.

Otra posible aplicación sería la integración de la predicción dentro de herramientas internas de los clubes, combinando el valor estimado con información adicional sobre contratos, costes de transferencia, edad, posición y necesidades de la plantilla. De esta forma, la predicción constituiría una de las variables utilizadas en un proceso de análisis más amplio.

En este sentido, la principal aportación empresarial del trabajo no reside únicamente en obtener una predicción individual, sino en establecer un proceso reproducible que transforma datos de jugadores en información cuantitativa utilizable para apoyar la toma de decisiones.

Bibliografía

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Franceschi, M., et al. (2024). Determinants of football players' valuation: A systematic review. *Journal of Economic Surveys, 38*(3), 577–600. https://doi.org/10.1111/joes.12552

Frick, B. (2007). The football players' labor market: Empirical evidence from the major European leagues. *Scottish Journal of Political Economy, 54*(3), 422–446. https://doi.org/10.1111/j.1467-9485.2007.00423.x

Herm, S., Callsen-Bracker, H.-M., & Kreis, H. (2014). When the crowd evaluates soccer players' market values: Accuracy and evaluation attributes of an online community. *Sport Management Review, 17*(4), 484–492. https://doi.org/10.1016/j.smr.2013.12.006

Kelly, A. L., et al. (2021). How relative age effects associate with football players' market values: Indicators of losing talent and wasting money. *Frontiers in Sports and Active Living, 3*. https://pmc.ncbi.nlm.nih.gov/articles/PMC8309691/

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems, 30*. https://arxiv.org/abs/1705.07874

Serna Rodríguez, M., Ramírez Hassan, A., & Coad, A. (2019). Uncovering value drivers of high performance soccer players. *Journal of Sports Economics, 20*(6), 819–849. https://doi.org/10.1177/1527002518808344

dcaribou. (2026). *Football data from Transfermarkt* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/davidcariboo/player-scores

Anexos

Anexo I. Notebook y resultados técnicos

El desarrollo completo del análisis, incluyendo el código Python, los estudios preliminares y los resultados técnicos adicionales, se encuentra recogido en el notebook exportado a formato HTML que acompaña al presente trabajo.

Anexo II. Presentación y vídeo